¿Puedo lanzar Serverless sobre Kubernetes?

Patrones FaaS, escalado a cero y orquestación basada en eventos en Kubernetes utilizando **KEDA**.



Jhonnatan Gil
DevOps / SRE

JhonnyPong

linkedin.com/in/JhonnyPong

github.com/jthan24

instagram.com/JhonnyPong_col

© 2023 Cloud Native Computing Foundation



Promesa de Cloud Serverless

Escalado Automático: Respuesta instantánea a ráfagas de demanda.

Pago por Uso: Reducción de costos al escalar exactamente a 0.

Cero Operación: Foco exclusivo en el código de la función.



kubernetes - k8s

Control total de la infraestructura

Portabilidad multi-cloud

Estándar de la industria

Estandar OCI (Open Container initiative)

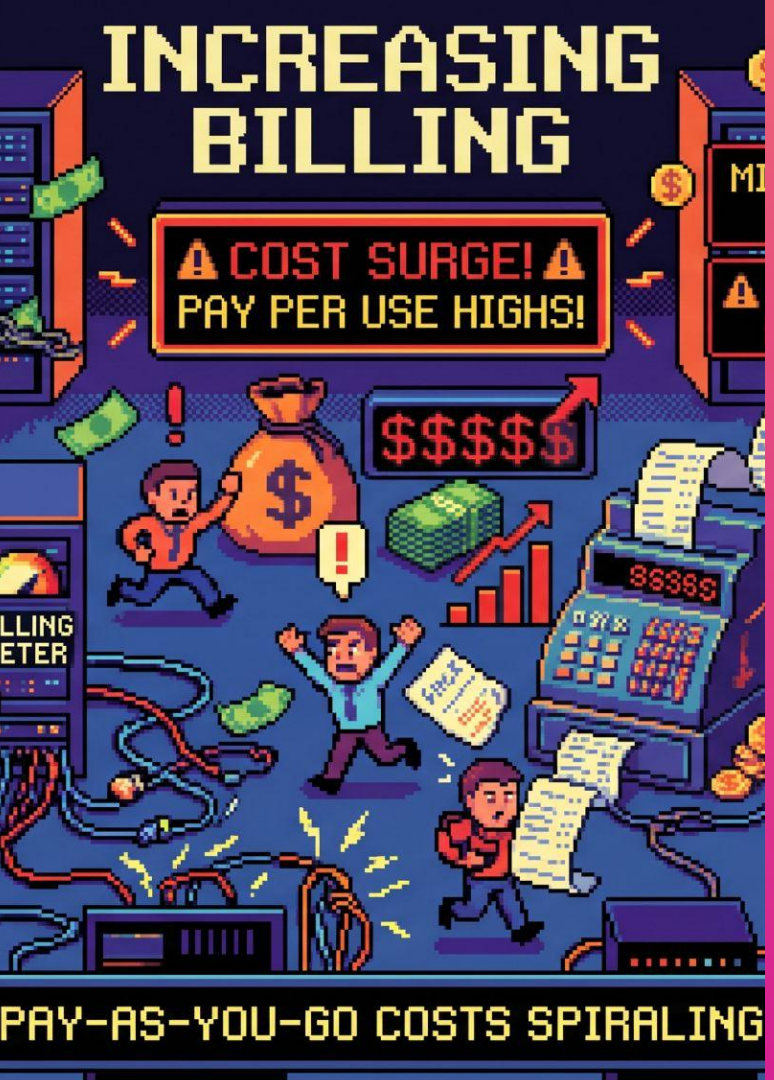


Dolores del FaaS



Vendor locking

Acoplamiento a APIs propietarias.



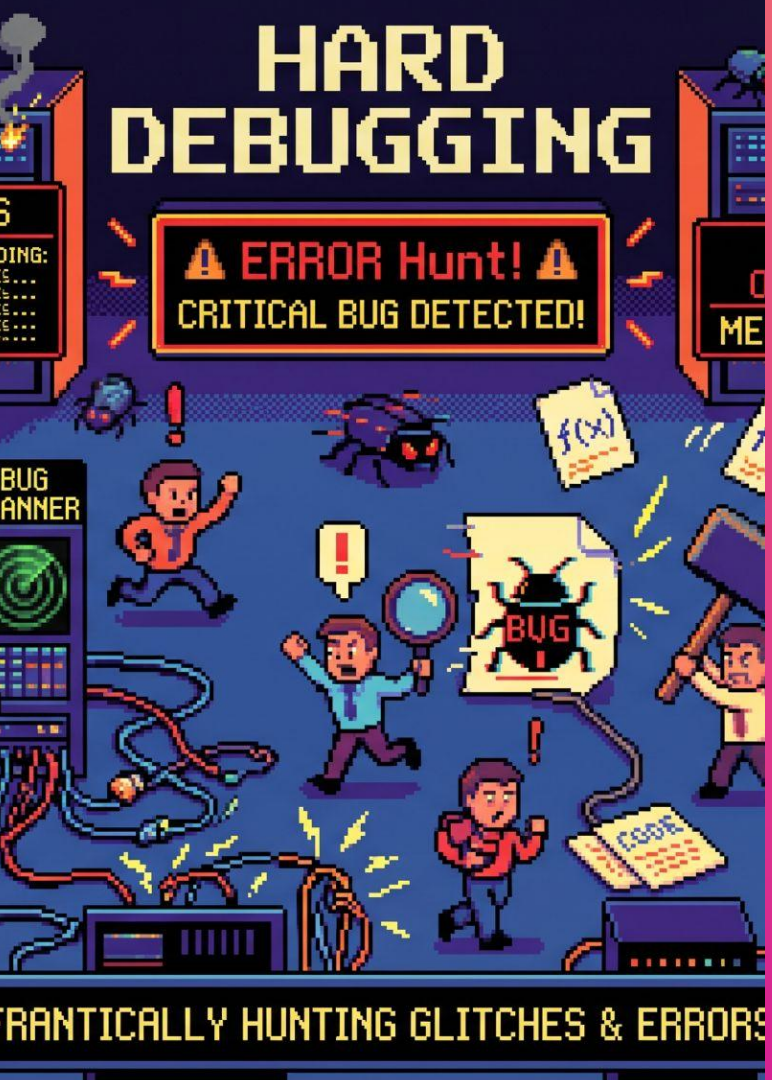
COSTO IMPREDECIBLE

Facturas sorpresa por tráfico alto.



LÍMITES DE EJECUCIÓN

Restricciones de tiempo y memoria por invocación.



DEBUG DIFÍCIL

Entornos locales no idénticos.



KEDA

Kubernetes Event-driven Autoscaling

KEDA

CNCF Graduated
- Máximo nivel de madurez, respaldado por la CNCF y una comunidad activa.

LIGERO & SINGLE-PURPOSE
- Hace una sola cosa bien: escalar pods.

60+ SCALERS
- RabbitMQ, Kafka, SQS, Prometheus y más.

NO-INTRUSIVO
- Aplica sobre Deployments y Jobs estándar.

© 2023 Cloud Native Computing Foundation
https://landscape.cncf.io/?item=orchestration-management--scheduling-orchestration--keda



CNCF Landscape

https://landscape.cncf.io/



© 2023 Cloud Native Computing Foundation

Lo que NO es KEDA



No ejecuta ni empaqueta tu código fuente.



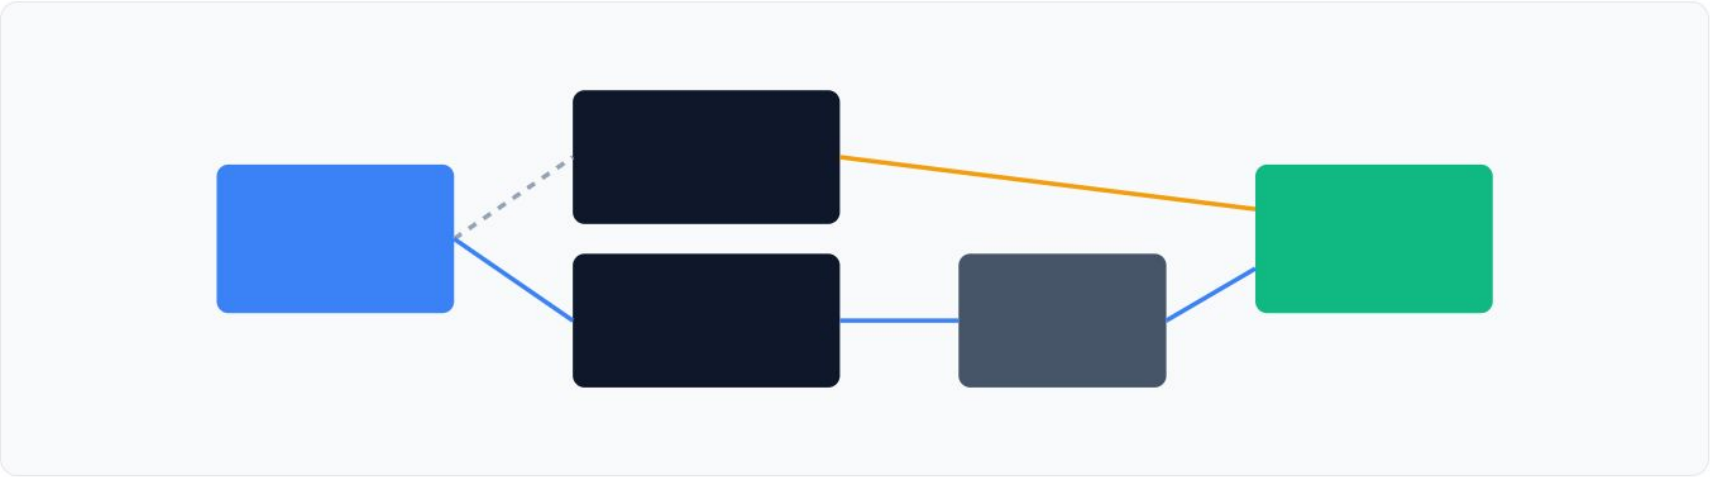
Extiende el HPA nativo de Kubernetes.



No añade capas compuestas de UI o API Gateway.

© 2023 Cloud Native Computing Foundation

Bajo el capó



1. Fuente de Eventos
Kafka, SQS, RabbitMQ

2. KEDA Controller
Escala 0 → 1 y 1 → 0

3. Metrics Adapter
Alimenta métricas al HPA

4. Target Workload
Deployment / Job / Pod

© 2023 Cloud Native Computing Foundation

Ciclo de vida

0

replicas

reposos

KEDA monitorea la fuente.

1

replica

activacion

Operador fuerza escalado inicial.

N

replicas

HPA takeover

Metrics Server alimenta al HPA.

0

replicas

cooldown

Escala a cero tras inactividad.

© 2023 Cloud Native Computing Foundation

Catalogo de scalers (60+)

RabbitMQ

Apache Kafka

AWS SQS

Prometheus

PostgresSQL

Cron / Time

GCP Pub / Sub

Redis

mongoDB

etc...

© 2023 Cloud Native Computing Foundation

https://keda.sh/



Anatomia del scaledObject

```yaml
apiVersion: keda.sh/v1alpha1
kind: ScaledObject
metadata:
  name: mongo-scaledobject
spec:
  scaleTargetRef:
    name: dummy-mongo          # Deployment objetivo
  minReplicaCount: 0           # Habilita escala a cero
  maxReplicaCount: 5           # Límite máximo
  triggers:
  - type: mongodb
    metadata:
      host: "10.1.1.1"
      port: "27017"
      ...
      queryValue: "1"          # Target: 1 pod por cada mensaje
```


© 2023 Cloud Native Computing Foundation





Secuencia

1: Llegan registros a la BD

2: KEDA operator detecta el insert > 0 y crea el 1mer Pod (0 → 1)

3: Metrics Server informa al HPA para escalar de 1 a N pods.

4: Sin eventos transcurridos cooldown, vuelven a 0 pods (N → 0)

© 2023 Cloud Native Computing Foundation



DEMO o miedo?

© 2023 Cloud Native Computing Foundation

Por que kubernetes?





repo

github.com/jthan24/serverless-col-lnazar-serverless-kubernetes

Ciclo de vida

0

replicas

reposos

KEDA monitorea la fuente.

1

replica

activacion

Operador fuerza escalado inicial.

N

replicas

HPA takeover

Metrics Server alimenta al HPA.

0

replicas

cooldown

Escala a cero tras inactividad.

© 2023 Cloud Native Computing Foundation

Summary

FaaS

k8s

Problematicas de FaaS (vendor locking, $$, recursos, tiempos de ejecucion, debug)

Keda (0 - 1 - N - 0)

© 2023 Cloud Native Computing Foundation

Invitación especial

https://ocgroups.dev/cncf/group/g9bdkpk



© 2023 Cloud Native Computing Foundation



Muchas gracias

JhonnyPong

github.com/jthan24

© 2023 Cloud Native Computing Foundation